

PIRO

Plataforma Integrada de Resposta Orbital

Camada de Engenharia de Dados Orbital

Big Data Architecture & Data Integration (BDDI)

FIAP - Global Solution 2026 - 1o Semestre

Engenharia de Software - 4o Ano - ESPW - Presencial

Tema: Industria Espacial - O Codigo que Move o Universo

Gerado automaticamente em 02/06/2026 22:10

1. Equipe

Nome completo	RM
Julia Marques	98680
Matheus Gusmao	550826
Guilherme Moraes	551981

2. Descrição da solução proposta

O PIRO é uma plataforma integrada que consome dados orbitais de satélites (NASA FIRMS - VIIRS), enriquece-os com dados meteorológicos (Open-Meteo), carrega de forma idempotente em Oracle Database e expõe consultas analíticas para alimentar o resto do sistema (camadas ACV de visão computacional, GAIE de aprendizado de máquina preditivo e RPA de automação de alerta).

Esta entrega corresponde à camada de Engenharia de Dados Orbital (BDDI): a fundação que consolida em um único banco relacional, com schema estável, todas as variáveis necessárias para que as camadas downstream operem sobre dados consistentes e auditáveis. A pipeline executa diariamente via Apache Airflow, é idempotente por construção (MERGE no Oracle) e expõe 6 consultas analíticas.

>> Diferenciais técnicos da entrega

1) MERGE idempotente comprovado - 2 execuções da DAG mantiveram 7.502 linhas em `focos_incendio` e `clima_associado`. 2) APIs reais como fonte primária (NASA FIRMS multi-dia + Open-Meteo em lote, sem chave). 3) Derivação geográfica UF/bioma por bounding box, sem dependência de shapefiles. 4) Pipeline resiliente a falhas parciais de API externa - fallback de mediana garante completude do dataset.

3. Objetivo do pipeline

Transformar a lista bruta de focos de incêndio detectados pelo sensor VIIRS em uma base relacional enriquecida com clima e geografia derivada, pronta para consumo analítico (consultas SQL) e por modelos de Machine Learning (camada GAIE). Especificamente:

- Extrair, diariamente, todos os focos do Brasil dos últimos 7 dias.
- Enriquecer cada foco com temperatura, umidade, vento e precipitação.
- Derivar UF e bioma a partir da latitude/longitude.
- Carregar no Oracle FIAP com chave natural `id_externo` (`lat|lon|data|hora`).
- Garantir idempotência: rodar a DAG N vezes não duplica linhas.
- Disponibilizar 6 consultas analíticas para visão operacional do oncall.

4. Fonte de dados utilizada

4.1 NASA FIRMS - VIIRS_SNPP_NRT

Endpoint: https://firms.modaps.eosdis.nasa.gov/api/area/csv/{KEY}/VIIRS_SNPP_NRT/{BBOX}/1/{DATE}

Parametro	Valor
Sensor	VIIRS_SNPP_NRT (Suomi-NPP)

Resolucao	375m (vs 1km do MODIS)
Bounding box Brasil	-74, -34, -34, 6
Estrategia	Loop dia-a-dia (limite area x
Janela utilizada	7 dias
Chave de API	Gratuita - 5.000 transacoes /
Volume real coletado	7.762 focos brutos

4.2 Open-Meteo - Forecast endpoint

Endpoint: <https://api.open-meteo.com/v1/forecast>


Parametro	Valor
Chave de API	Nao requer - 100% gratuito
Tamanho do lote	100 coordenadas por request
Variaveis colhidas	temperature_2m, relative_humid
Retentativas	3 com backoff linear (1.5s x t
Hit rate observado	1.400 / 7.502 focos (18.6%)
Fallback	Imputacao por mediana em trans

4.3 Oracle Database FIAP - sink analitico

Parametro	Valor
Host	oracle.fiap.com.br
Porta	1521
SID	ORCL
Acesso	Internet publica (sem VPN)
Driver Python	python-oracledb 2.2 (modo thin

5. Arquitetura do pipeline

Fluxo visual: fonte -> extracao -> staging -> transformacao -> carga no Oracle -> analise SQL. Cada tarefa da DAG e fina e chama uma funcao de um modulo em src/, permitindo teste isolado fora do Airflow.



A DAG roda em @daily com 2 retries automaticos (retry_delay=2min) e usa XCom para passar os caminhos dos CSVs intermediarios entre tarefas. A tarefa 'analisar' executa em paralelo logico apos 'transformar', gerando logs de sanity-check (top 5 estados, media FRP) que servem para validacao rapida antes de consultar o Oracle. A tarefa 'armazenar_temp' cumpre o requisito explicito do edital de existencia de um passo de armazenamento intermediario entre extracao e transformacao.

6. Explicacao das etapas da DAG

#	Tarefa	Funcao chamada	Saida XCom
1	extrair	extrair_focos(dias=7) + extrai	Caminhos: focos_raw.csv + clim
2	armazenar_temp	pd.merge dos 2 CSVs em focos_c	Caminho stage_focos_clima.csv
3	transformar	transformacao.transformar(foco	Caminho focos_tratados.csv
4	carregar_oracle	carga_oracle.carregar(df)	Numero de registros confirmado
5	analisar	Sanity-check Python (top 5 est	Print no log

A tarefa 2 cumpre o requisito explicito do edital de existencia de um passo de armazenamento temporario (staging) entre extracao e transformacao.

7. Transformacoes realizadas

Sequencia aplicada em src/transformacao.py, com justificativa tecnica de cada passo:

#	Passo	Por que existe
1	dropna(latitude, longitude)	Sem coordenada nao se geocodif
2	to_datetime(data)	Permite filtros temporais nas
3	_normaliza_confianca	FIRMS mistura % (MODIS) e l/n/
4	confianca >= 30	Descarta deteccoes de baixa co
5	drop_duplicates(id_externo)	Loop multi-dia FIRMS pode dupl
6	merge(clima, on=id_externo)	Anexa colunas climaticas

7	fillna(median()) em clima	Trata NaN do Open-Meteo (~80%
8	_bbox_match em UF	Deriva UF sem dependencia geoe
9	_bbox_match em bioma	Deriva bioma sem dependencia g
10	estacao_seca = (u<30 & p<1)	Feature binaria de risco clima

8. Modelagem das tabelas Oracle

Estrela com 1 fato e 2 dimensoes-satelite. Relacionamentos:

focos_incendio (1) ---< (N) clima_associado (1:1 na pratica)
focos_incendio (1) ---< (N) imagens_satelite_metadata (preenchida pela ACV)

8.1 focos_incendio (fato)

Coluna	Tipo	Descricao
id_foco	NUMBER IDENTITY	PK auto-incremento
id_externo	VARCHAR2(60) UNIQUE	Chave natural lat lon data hor
latitude	NUMBER(9,4)	Coordenada
longitude	NUMBER(9,4)	Coordenada
data_foco	DATE	Data da deteccao
satelite	VARCHAR2(20)	N, 1, Aqua, Terra
confianca	NUMBER(5,1)	% de confianca
brilho	NUMBER(7,1)	Temperatura de brilho (K)
frp	NUMBER(8,1)	Fire Radiative Power (MW)
estado	VARCHAR2(2)	UF por bounding box
bioma	VARCHAR2(20)	Bioma por bounding box

8.2 clima_associado (1:1 com focos)

Coluna	Tipo	Descricao
id_clima	NUMBER IDENTITY	PK
id_externo	VARCHAR2(60) UNIQUE FK	Chave do MERGE
temperatura	NUMBER(5,1)	Celsius (Open-Meteo)
umidade	NUMBER(5,1)	% (Open-Meteo)
vento	NUMBER(5,1)	km/h
precipitacao	NUMBER(6,1)	mm
estacao_seca	NUMBER(1)	0/1 derivado

8.3 imagens_satelite_metadata (1:N com focos)

Coluna	Tipo	Descricao
id_imagem	NUMBER IDENTITY	PK
id_externo	VARCHAR2(60) FK	Foco relacionado
url_tile	VARCHAR2(400)	URL do tile satelite
resolucao	VARCHAR2(20)	375m, 10m, etc
classificacao	VARCHAR2(20)	fogo / nao_fogo (CNN)
confianca_cnn	NUMBER(5,1)	% da CNN

8.4 Indices criados

Indice	Coluna	Consultas beneficiadas
idx_focos_data	focos_incendio.data_foco	Consultas 1 e 2
idx_focos_estado	focos_incendio.estado	Consultas 1 e 6

idx_focos_bioma	focos_incendio.bioma	Consultas 3 e 6
idx_clima_idext	clima_associado.id_externo	JOIN clima<->focos

9. Prints das execucoes no Apache Airflow

9.1 Graph view - 5 tarefas verde



Fig 1. DAG piro_pipeline_queimadas com as 5 tarefas em status SUCCESS.

9.2 DAG Runs summary - 2 execucoes

DAG Runs Summary	
Total Runs Displayed	2
■ Total success	2
First Run Start	2026-06-02, 21:41:10 UTC
Last Run Start	2026-06-02, 21:48:15 UTC
Max Run Duration	00:20:37
Mean Run Duration	00:17:06
Min Run Duration	00:13:34

Fig 2. Summary com Total success: 2, evidencia das 2 execucoes exigidas pelo edital.

10. Tabelas populadas no Oracle Database

10.1 Contagem das tabelas após 2 execuções

Tabela	Linhas	Esperado
focos_incendio	7.502	7.502 (= após 1 run; MERGE não)
clima_associado	7.502	7.502 (1:1 com focos)
imagens_satelite_metadata	0	Será populada pela camada ACV

>> Prova de idempotência via MERGE

Os 7.502 focos coletados na primeira execução (após dedup dos 7.762 brutos) foram inseridos no Oracle. Na segunda execução, o MERGE INTO ... WHEN NOT MATCHED THEN INSERT detectou que todos os id_externo já existiam e não duplicou nenhuma linha. A contagem final continua em 7.502 - definição formal de operação idempotente.

10.2 Trecho do log da tarefa extrair

```
[2026-06-02T21:48:25.269+0000] {logging_mixin.py:188} INFO - [FIRMS] 7762 focos REAIS coletados em 7 dia(s).
[2026-06-02T22:01:25.948+0000] {logging_mixin.py:188} INFO - [Open-Meteo] clima REAL para 1400 focos.
[2026-06-02T22:01:26.026+0000] {taskinstance.py:1206} INFO - Marking task as SUCCESS.
dag_id=piro_pipeline_queimadas, task_id=extrair, run_id>manual__2026-06-02T21:44:09.959144+00:00,
execution_date=20260602T214409, start_date=20260602T214817, end_date=20260602T220126
```

10.3 Trecho do log da tarefa carregar_oracle

```
[2026-06-02T22:01:45.189+0000] {logging_mixin.py:188} INFO - [oracle] 7502 focos+clima carregados (idempotente via MERGE).
[2026-06-02T22:01:45.190+0000] {logging_mixin.py:188} INFO - [load] 7502 registros confirmados no Oracle.
[2026-06-02T22:01:45.193+0000] {taskinstance.py:1206} INFO - Marking task as SUCCESS.
dag_id=piro_pipeline_queimadas, task_id=carregar_oracle, run_id>manual__2026-06-02T21:44:09.959144+00:00,
execution_date=20260602T214409, start_date=20260602T220143, end_date=20260602T220145
[2026-06-02T22:01:45.233+0000] {local_task_job_runner.py:243} INFO - Task exited with return code 0
```

11. Consultas analíticas em SQL

Arquivo completo em sql/02_consultas.sql. As 6 consultas exercitam, no mínimo, WHERE, GROUP BY, JOIN (inclusive de 3 tabelas), HAVING, agregações (COUNT/AVG/MIN/MAX/SUM), ORDER BY, FETCH FIRST e funções temporais.

```
-- =====
-- PIRO · BDDI - Consultas analíticas (Oracle SQL)
-- 6 consultas (mínimo exigido: 5). Usam filtros, agrupamentos,
-- funções de agregação, ordenação e JOINS.
-- =====
```

```
-- -----
-- 1) Ranking de estados com mais focos no último mês
-- (WHERE por data + GROUP BY + COUNT + ORDER BY)
-- -----
```

```
SELECT estado,
       COUNT(*)          AS total_focos,
       ROUND(AVG(frp), 1) AS frp_medio
FROM   focos_incendio
WHERE  data_foco >= ADD_MONTHS(TRUNC(SYSDATE), -1)
GROUP BY estado
ORDER BY total_focos DESC;
```

```
-- -----
-- 2) Evolução diária de focos nos últimos 30 dias
-- (agregação temporal por dia)
-- -----
```

```
SELECT TRUNC(data_foco) AS dia,
       COUNT(*)         AS focos_no_dia
FROM   focos_incendio
WHERE  data_foco >= TRUNC(SYSDATE) - 30
GROUP BY TRUNC(data_foco)
ORDER BY dia;
```

```
-- -----
-- 3) Correlação clima x focos por BIOMA (JOIN entre tabelas)
-- Junta focos com clima e agrega por bioma.
-- -----
```

```
SELECT f.bioma,
       COUNT(*)          AS qtd_focos,
       ROUND(AVG(c.temperatura), 1) AS temp_media,
       ROUND(AVG(c.umidade), 1)    AS umidade_media,
       ROUND(AVG(c.vento), 1)      AS vento_medio,
       SUM(c.estacao_seca)         AS focos_em_seca
FROM   focos_incendio f
JOIN   clima_associado c ON c.id_externo = f.id_externo
GROUP BY f.bioma
ORDER BY qtd_focos DESC;
```

```
-- -----
-- 4) Top 10 áreas mais críticas por intensidade (FRP)
-- (ordenação + limite de linhas)
-- -----
```

```
SELECT id_externo, estado, bioma, frp, brilho, data_foco
FROM   focos_incendio
ORDER BY frp DESC
FETCH FIRST 10 ROWS ONLY;
```

```
-- -----
-- 5) Estatísticas por satélite (MIN / MAX / AVG / COUNT)
-- -----
```

```
SELECT satellite,
       COUNT(*)          AS qtd,
       MIN(frp)          AS frp_min,
       ROUND(AVG(frp), 1) AS frp_medio,
       MAX(frp)          AS frp_max,
       ROUND(AVG(confianca), 1) AS confianca_media
FROM   focos_incendio
GROUP BY satellite
HAVING COUNT(*) > 0
ORDER BY frp_medio DESC;
```

```

-- -----
-- 6) Focos criticos cruzados com classificacao da CNN
-- JOIN de 3 tabelas (foco + clima + imagem) + filtros compostos.
-- LEFT JOIN com imagens_satelite_metadata garante linhas mesmo
-- quando a camada ACV ainda nao classificou o tile.
-- -----
SELECT f.estado,
       f.bioma,
       COUNT(*)                AS focos_criticos,
       ROUND(AVG(f.frp), 1)    AS frp_medio,
       ROUND(AVG(c.umidade), 1) AS umidade_media,
       ROUND(MAX(f.frp), 1)    AS frp_max
FROM   focos_incendio f
JOIN   clima_associado c      ON c.id_externo = f.id_externo
LEFT JOIN imagens_satelite_metadata i ON i.id_externo = f.id_externo
WHERE  f.frp > 50
       AND (i.classificacao = 'fogo' OR i.classificacao IS NULL)
GROUP BY f.estado, f.bioma
ORDER BY focos_criticos DESC;

```

12. Resultados obtidos pelas consultas

Consulta 1 - Ranking de estados (ultimo mes)

estado	total_focos	frp_medio
MT	2.345	6,8
??	1.349	5,5
TO	909	10,4
PA	753	7,8
MA	362	7,4
BA	357	7,4
MG	351	4,2
AM	287	7,1
MS	206	5,3
RO	206	8,4

Leitura: Mato Grosso lidera com 31% do total. Os 1.349 focos com estado '??' são pontos fora das 19 bounding boxes embutidas em transformacao.py (limitacao documentada). Top-5 estados validos: MT, TO, PA, MA, BA - eixo classico do Arco do Desmatamento.

Consulta 2 - Evolucao diaria

dia	focos_no_dia
2026-05-27	1.525
2026-05-28	1.696
2026-05-29	1.306
2026-05-30	962
2026-05-31	1.015
2026-06-02	998

Consulta 3 - Clima x focos por bioma (JOIN)

bioma	qtd_focos	temp_medio	umidade_medio	vento_medio	focos_em_seca
Cerrado	2.823	25,3	68,3	7,7	0
Mata Atlantica	1.569	25,5	66,7	7,6	0
Desconhecido	1.480	24,9	71,0	7,3	4
Amazonia	1.056	25,9	67,3	7,6	0
Caatinga	382	25,3	68,7	8,1	0
Pampa	102	23,9	70,8	8,1	0
Pantanal	90	25,4	68,9	7,3	0

Consulta 4 - Top 10 areas criticas por FRP

UF	Bioma	FRP (MW)	Brilho (K)	Data
MT	Cerrado	214,0	342,8	2026-05-31
TO	Mata Atlantica	195,0	367,0	2026-05-30
GO	Cerrado	176,5	354,4	2026-05-28
MT	Cerrado	172,6	349,8	2026-06-02
BA	Caatinga	164,5	367,0	2026-05-29
TO	Cerrado	150,1	352,0	2026-05-31
MT	Cerrado	147,7	357,5	2026-06-02
MT	Cerrado	130,5	353,9	2026-05-30
MT	Cerrado	130,5	367,0	2026-05-30
TO	Mata Atlantica	129,7	352,4	2026-06-02

7 dos 10 maiores focos estao em MT/Cerrado. Cinco deles concentrados em -14,0 lat x -58,8 lon - provavel incendio unico de grande extensao detectado como multiplos pontos pelo sensor VIIRS. Exatamente o tipo de evento que o modelo GAIE precisa marcar como alto_risco.

Consulta 5 - Estatisticas por satelite (HAVING)

satelite	qtd	frp_min	frp_medio	frp_max	confianca_media
N (VIIRS Suomi-NPP)	7.502	0,1	7,1	214,0	66,3

Consulta 6 - JOIN de 3 tabelas (focos x clima x imagens CNN)

JOIN de 3 tabelas (focos_incendio + clima_associado + imagens_satelite_metadata) com filtro composto. A versao inicial usava $f.frp > 100$ AND $c.umidade < 35$, mas a interseccao retornava vazia porque a falha parcial do Open-Meteo deixou 78% dos focos com mediana imputada (umidade ~68%, incompativel com < 35). Limiar ajustado para $f.frp > 50$, preservando o JOIN de 3 tabelas e o conceito de 'foco intenso' enquanto entrega dados utilizaveis. O LEFT JOIN com imagens_satelite_metadata antecipa a integracao com a camada ACV.

===== Consulta 6: SELECT f.estado,

>> Observacao tecnica - estacao_seca quase sempre zero

A consulta 3 mostra focos_em_seca = 0 em quase todos os biomas. Isso nao e bug da regra de derivacao ($umidade < 30$ AND $precipitacao < 1$) e sim consequencia direta da falha parcial do Open-Meteo nesta execucao: 78% dos focos ficaram com $umidade = mediana = 68\%$, valor incompativel com o predicado de seca. A proxima iteracao usara batches menores (50 coords) e sleep maior (1,5s) para elevar o hit rate do Open-Meteo a $> 80\%$.

13. Conclusao tecnica da equipe

A camada BDDI do PIRO entrega uma pipeline completa, idempotente e auditavel, que ingere dados reais da NASA FIRMS e da Open-Meteo, processa em Python via DAG Airflow com 5 tarefas encadeadas, e carrega no Oracle Database FIAP via MERGE. Em homologacao, 7.502 focos do periodo 27/05 a 02/06/2026 foram processados, sobreviveram a duas execucoes consecutivas da DAG sem duplicacao e foram analisados por 6 consultas SQL cobrindo ranking por estado, evolucao temporal, correlacao clima/bioma, top FRP, estatisticas por satellite e join de tres tabelas.

Pontos fortes da implementacao

- APIs reais como fonte primaria (nao demonstracao com mock).
- Separacao limpa entre DAG (orquestracao) e src/ (logica), com cada modulo testavel.
- MERGE idempotente comprovado experimentalmente (contagem estavel apos 2 runs).
- Resiliencia a falha parcial: pipeline conclui em verde mesmo com 78% dos clima requests falhando, gracias ao fillna(median()) em transformacao.
- Modelagem em estrela com indices justificados pelas consultas-alvo.

Limitacoes identificadas

- Hit rate baixo do Open-Meteo (18.6%) por rate-limit interno - sera mitigado com batches menores e sleep maior na proxima iteracao.
- Derivacao UF/bioma por bounding box gera 1.349 focos com estado '??' (estados de fronteira curva). PostGIS ou shapefiles do IBGE resolveriam.
- estacao_seca artificialmente baixo nas consultas devido a mediana imputada de umidade - dependente da correcao do hit rate do Open-Meteo.
- Sem captura de evolucao temporal (mesmo foco re-detectado): atual MERGE INSERT-only descarta updates. Requer WHEN MATCHED THEN UPDATE para v2.

Caminho para evolucao em producao

1. Substituir Sequential por Local/Celery Executor com Postgres como metadata DB.
2. Adicionar alertas Slack/email em falhas via on_failure_callback no DAG.
3. Migrar carga para Oracle Hook do Airflow (apache-airflow-providers-oracle).
4. Implementar materialized views para consultas 3 e 6 (cache automatico).
5. Adicionar testes unitarios em src/transformacao.py via pytest.
6. Empacotar como custom Docker image, eliminando _PIP_ADDITIONAL_REQUIREMENTS.

PIRO - Camada de Engenharia de Dados Orbital - Pipeline real com dados reais.